

基于深度学习 U-Net 模型的石块图像分割算法

Segmentation of Rock Images Based on U-Net

徐江川 金国强 朱天奕 余芬芬 郭杰 金一 竺长安

(中国科学技术大学精密机械与精密仪器系,安徽 合肥 230027)

摘要:为了产出高质量的水泥成品,需要对其中间成品进行尺寸分布估算。利用图像处理的方法是一种方便快捷的选择,其中最重要的工作就是将图像中的石块准确分割开,采用了一种叫 U-Net 的深度卷积网络。从 7 张石块图片中随机截取的 840000 个小样本作为训练数据,5 张图像作为测试数据集,包含过度分割和分割不足的平均错误率是 9.37%。另外也对两张来自网络上的石块图片也进行测试,其错误率分别是 16.54% 和 22.18%。最后,把预测的石块图像累积尺寸分布图 and 标准进行对比,结果显示 U-Net 方法在实际应用中是可行的、鲁棒的。

关键词:图像分割,深度学习,石块,知识迁移

Abstract:In order to produce high-quality cement products,the size distribution of their intermediate products needs to be estimated.The image processing method is a convenient and quick choice,the most important step is the accurate segmentation of rock images,a deep convolution network called U Net is applied.The network is trained with 840000 samples that are randomly extracted from seven rock images.Then,five images are tested,and the results are compared with ground truth images.The average miss rate,including over-and under-segmentation,is 9.37%.Two images obtained from the Internet are also tested,and the miss rates are 16.54% and 22.18%.Furthermore,the estimated accumulative size distributions of the seven test images are compared with ground truth images.

Keywords:image segmentation,deep learning,rock,knowledge transfer

在采矿业,矿石碎片的尺寸估算在许多工业部门起着至关重要的作用^[1],其中机器视觉方法石块图像分割是该图像分析的核心。获取每一石块像素级别区域是非常困难的,因为石块之间经常是相互重叠的而不是孤立的。针对这个问题,许多图像处理方法被提出,其中绝大部分是灰度化、归一化、滤波和分水岭分割等基本步骤的相结合^[2],当然也有些人试图提高改善现有的算法,特别是分水岭分割算法^[3-4],然而,这些方法在实际应用中是有局限性的并且需要比较精细的参数调整。

深度学习最近已经被广泛地应用,其中深度卷积网络在图像的分类问题中有非常准确、高效的效果^[5],而图像的分割问题可以看作是在像素级别上的分类问题,因此许多的研究人员利用深度卷积网络来解决图像分割问题,特别是在医疗图像领域^[6]。Cerroloza^[7]和 Maji^[8]采用了深度卷积网络来对眼底血管图像进行分割,效果优于那些传统的图像处理方法。而眼底血管图像和石块图像在分割方面有下面几个相同点:①眼底图像中的血管和石块图像中石块间的间隙都是细条状的;②血管和石块间隙都是遍布于整个图像中,并且属于一个连通域;③血管和石块的分割都是对每个像素是否属于目标(血管、间隙)的二分类。


因此,深度学习是能够适合石块分割任务的,经过调研,一种名为 U-Net^[9]的深度卷积网络被采用来对图像进行分割。这种网络包含一个捕捉上下文信息的路径和一个对称的扩展路径,可以实现精确的分割,另外 U-Net 可以对训练数据集高效的利用,减小了对样本量的需求。整个数据集包含 7 张训练图片和 5 张测试图片,总数 840000 个训练样本是从 7 张训练图像中平均随机截取得到的,平均每张图片截取 120000 个样本,每个样本尺寸是 48×48。训练之后我们把测试图片的分割效果和人工分割效果进行了对比。

1 图像分割算法

1.1 数据准备

实验样品是水泥的一种中间产物:熟料,主要呈块状。为了对实验样品拍摄,搭建了一个包含石块容器和拍摄手机的实验平台,通过人工描绘石块边界得到人工分割图,12 张图片总共


耗时 21 小时。图 1 显示原始图片 and 其对应的人工分割图片。



a,b 原始图片;c,d 对应的人工分割图片

图 1 原始图片与人工分割图片对比

从图 2a 看到石块纹理比较复杂、对比度不够明显,这些因素都会影响最后的分割效果,另外原始图片是 RGB 格式,会增加网络训练中的计算复杂度。对此我们采用了下面几个预处理步骤,灰度化、均值滤波和自适应直方图均衡化。从图 2 可以看到石块间的间隙更加凸显。



a 原始 RGB 图像 b 灰度图 c 均值滤波后的图

d 自适应直方图均衡化之后效果图

图 2 图片处理效果

1.2 U Net 网络结构

U Net 网络的前半部分和传统的卷积网络相同,进行了卷

积、激活和池化等操作,其中每一次池化都使得网络层的分辨率为原来的 1/4;后半部分中通过升采样逐步提高了网络层的分辨率,并且通过在网络层通道维上和浅层网络层堆叠,使得浅层、深层网络层的信息相融合,弥补了因为前面池化操作带来的信息损失。最后当网络层分辨率和输入层分辨率相同时,再次进行了两次卷积和一次全连接操作,图 3 展示了整个网络结构。

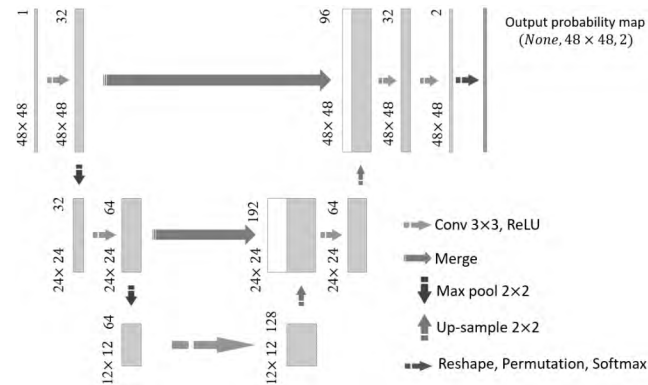


图 3 整个网络结构图

图 3 输入尺寸是 48×48 的 U-Net 网络结构,灰色矩形表示网络层,最上面的数字代表特征通道数,下面的数字表示网络层分辨率,白色矩形表示浅层融合的网络层。

整个网络的输出的形状是 (None, 48×48, 2), 第一个参数代表参与训练的样本数,后面的三个参数代表了输入图片每一个像素是否属于石块的概率图,和人工分割的样本相对应。图 4 展示了部分训练样本和对应的人工分割样本。




图 4 部分训练样本和对应的人工分割标注


2 实验结果和讨论

2.1 测试图片结果

在测试过程中,通过在图片边界补零的方法使得图片的长和宽是 48 的倍数,使得任意分辨率的图片都能进行测试。另外对测试图片进行截取样本时是滑动窗形式,并且窗口是部分重叠的,这使得重合区域点的概率不单取决于一个测试样本在这点的概率值,而是多个包含该区域点的样本在这点概率的平均值,结果更准确。实验配置是:基于 Tensorflow 的 Keras 框架,Intel i7-6700k CPU 和 NVIDIA GTX 1080 图形显卡,训练耗时 70 小时左右。

图 5 展示对石块图片的分割效果。a 到 d 分别是测试图片、U-Net 输出概率图、取阈值 0.05 之后的二值化图和填充空洞图。可以看到石块被比较完整、精确的分割出来。图 5e 把分割图边界描绘为红色,图 5f 是为了更好可视化分割效果的伪彩色图。另外为了更好的展示效果,将其与人工分割效果图 5g~h 对比,对比看到绝大部分边界分割都是和人工分割效果一致的,但也有一些瑕疵。

为了更好地量化分割效果,统计了过分割和欠分割石块的数量占比,其中过分割是指在人工分割图中一个石块在 U-Net 分割图中被分割为多块,欠分割指的是多块石块在预测分割图中被当作一块,除了这两类之外,则是正确分割石块,其预测分割边界要和人工分割边界大致相同。定义 CM 是正确分割的石块数目,US 是欠分割的石块数目,OS 是过度分割的数目^[3]。



a 预处理后的石块图像 b U-Net 输出的概率图 c 二值化和取反
d 填充空洞 e 原始图片加上预测分割的轮廓线 f 预测的分割图
g 原始图片加上人工分割的轮廓线 h 人工分割图

图 5 图片分割效果

其错误率是 11.4%。

另外 U-Net 分割算法是为了帮助估算石块尺寸分布,统计了 U-Net 分割得到的累积石块尺寸概率分布图,并和人工分割效果进行对比。为了得到石块的等效直径,把每个石块当作圆形,那么其等效直径可以根据下面的公式计算:

$$D = \sqrt{\frac{4 \text{ region area}}{\pi}}$$




图 6 测试图片 1 的累积尺寸分布图

图 6 显示了测试图片的预测分割累积尺寸分布和人工分割的累积尺寸分布,两条曲线是非常接近的,这表明 U-Net 分割算法可以起到很好的石块尺寸估计的作用。另外,7 张图片用于网络训练,5 张图片用于测试,表 1 统计了测试的分割效果,其平均分割错误率是 9.37%,这个结果表明了 U-Net 算法在石块分割的应用中是准确、可行的。

表 1 测试图片分割效果量化结果

Image Id	CM	US	OS	Total	% Error
1	272	30	5	307	11.40
2	645	39	5	689	6.39
3	368	40	7	415	11.33
4	403	33	3	439	8.20
5	418	44	1	473	9.51
Mean					9.37

2.2 知识迁移

两张从网上下载的不同于训练图片风格的石块图片被用于测试 U-Net 网络的知识迁移的特点。经过和人工分割图像对比,它们的错误分割石块占比是 16.54%和 22.18%,也都把图中的石块大致分割出来。测试的结果显示之前训练的 U-Net 网络也能够对不同风格的石块图片进行分割,这体现了深度学习的知识迁移的特点,也就是其鲁棒性很好。

(下转第 102 页)

0.95、0.90、0.85 和 0.80 四种额定置信区间水平参数。这里引入新的指标来计算平均意义上的区间预测结果,如下:

$$X_{CP} = \frac{1}{T} \sum_{j=1}^T X_{CP}$$
$$X_{MWP} = \frac{1}{T} \sum_{j=1}^T X_{MWPj}$$
$$X_{CEI} = X_{MWP} \times e^{|\eta^{X_{CP}-\mu}|}$$

(8)

不同结构不同置信区间下的 X_{CP} 、 X_{MWP} 和 X_{CEI} 数据见图 4。

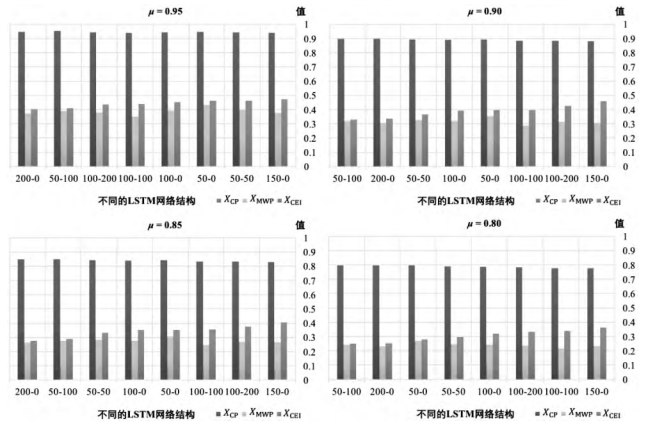


图 4 区间预测数值结果

从图 3 可以看出,高用电负荷对应的预测区间比低用电负荷更宽,并且强烈的局部波动导致更宽的预测区间。如图 4 所示,虽然计算得到的平均覆盖概率略低于给定的额定置信水平,但已经足够接近;随着额定置信水平的降低,平均宽度百分比值逐渐降低,与预期相符。不同的 LSTM 模型按照 X_{CEI} 的增大从左到右的顺序依次排列。结构 ($H_1=200, H_2=0$) 和 ($H_1=50, H_2=100$) 在四

个额定置信水平下表现更好,结构 ($H_1=150, H_2=0$) 表现较差。

3.3 LSTM 和传统神经网络对比

构造与 LSTM 结构具有相同隐层节点参数的传统神经网络模型进行点预测和区间预测,结果可以看出,LSTM 方法的点预测比 NN 方法更精确,LSTM 的区间预测性能优于 NN 方法。

参考文献

[1]Shen Z,Wu X,Guerrero J M,et al.Model-independent approach for short-term electric load forecasting with guaranteed error convergence[J]. Iet Control Theory & Applications, 2016, 10(12):1365-1373

[2]万志宏.基于时间序列的电力系统短期负荷预测研究[D].广州:华南理工大学,2012

[3]王成龙.基于卡尔曼滤波的短期负荷预测[J].电源技术应用,2013 (5):471,476

[4]胡玲.基于模糊神经网络的短期电力负荷预测研究[D].衡阳:南华大学,2011

[5]浦星材,沈晓风,张清扬,等.基于偏最小二乘法的支持向量机短期负荷预测[J].电网与清洁能源,2011,27(10):32-35

[6]陈杰,高翠云,胡翀.基于 PSO-Elman 神经网络的短期电力负荷预测[J].安徽建筑大学学报,2016,24(1):82-86

[7]师彪,李郁侠,于新花,等.基于改进粒子群-模糊神经网络的短期电力负荷预测[J].系统工程理论与实践,2010,30(1):157-166

[8]Paliwal M, Kumar U A. Review: Neural networks and statistical techniques: A review of applications[J]. Expert Systems with Applications, 2009, 36(1):2-17

[9]方仍存,周建中.应用聚类算法和混沌理论的短期负荷概率性区间预测[J].电网技术,2010,34(11):70-76

[收稿日期:2017.11.22]

(上接第 99 页)




图 7 网上下下载的测试图片,和之前训练的石块图片风格不同

表 2 测试图片 6、7 的分割效果量化结果

Image Id	CM	US	OS	Total	% Error
6	545	40	68	653	16.54
7	842	208	32	1082	22.18

3 结束语

针对实验结果分析表明,U-Net 网络能够很好地对石块图片进行准确的分割,可以达到尺寸准确估计的目的,具有良好的知识迁移特性。

参考文献

[1]T Motoi,Y Ohira,E Obata.Measurement of the floating particle size distribution by a buoyancy weighing-bar method [J]. Powder Technology,2010,201(3) :283-288

[2]WD Lei,K Li,XP Wang.Improved Watershed Segmentation Method in Rock Fragmentation Analysis on Digital Photos [J]. Advanced Materials Research,2011,261-263 :1734-1737

[3]Zelin Zhang,JianguoYang,Xiaolan Su,et al.Multi-scale image segmentation of coal piles on a belt based on the Hessian matrix[J].颗粒学报(英文版),2013,11 (5) :549-555

[4]K Dong,D Jiang.Automated Estimation of Ore Size Distributions Based on Machine Vision [J]. Unifying Electrical Engineering and Electronics Engineering, Springer,2014,238 : 1125-1131

[5]A Krizhevsky,I Sutskever,GE Hinton.Imagenet classification with deep convolutional neural networks [J].International Conference on Neural Information Processing Systems,2012,60 (2):1097-1105

[6]W Zhang,R Li,H Deng,L Wang ,et al.Deep convolutional neural networks for multi-modality isointense infant brain image segmentation[J]. Proc IEEE Int Symp Biomed Imaging,2015, 108 :214

[7]M Melinsca,P Prentasic,S Loncaric.Retinal vessel segmentation using deep neural networks[C]//VISAPP(10th International Conference on Computer Vision Theory and Applications, 2015

[8]D Maji,A Santara,P Mitra,et al.Ensemble of deep convolutional neural networks for learning to detect retinal vessels in fundus images[R].arXiv e-print (arXiv:1603.04833)

[9]O Ronneberger,P Fischer,T Brox.U-net: Convolutional networks for biomedical image segmentation [C]// International Conference on Medical Image Computing & Computer-assisted Intervention. 2015,9351:234-241

[收稿日期:2017.12.26]